

2024年(第17届) 中国大学生计算机设计大赛

人工智能实践赛作品报告

作品编号:

作品名称: 慧语成音——面向国际传播的汉语辅助教学系

统

填写日期: 2024年4月17日

填写说明:

- 1、本文档适用于人工智能实践赛决赛;
- 2、尽管预选赛仅完成部分工作,但是本文档需要针对决赛做出方案设计;
- 3、正文、标题格式已经在本文中设定,请勿修改;标题#的快捷键为"Ctrl+#",正文快捷键为"Ctrl+0";
- 4、本文档应结构清晰,突出重点,适当配合图表,描述准确,不易冗长拖沓;
- 5、提交文档时,以PDF格式提交;
- 6、本文档内容是正式参赛内容的组成部分,务必真实填写。如不属实,将导致奖项等级降低甚至终止本作品参加比赛。

目 录

第 1 章 作品概述	1
1.1 主题创意来源与产生背景	1
1.2 作品的用户群体	1
1.3 主要功能	1
1.3.1 中文分级	1
1.3.2 智能推荐	1
1.3.3 语音问答	1
1.3.4 特色	2
1.3.5 推广前景	2
第 2 章 问题分析	2
2.1 问题来源	2
2.2 现有解决方案	3
2.3 本作品要解决的痛点问题	3
2.4 解决问题的思路	3
第 3 章 技术方案	4
3.1 总体技术思路	4
3.2 技术路线框架图	4
3.3 详细技术介绍	5
3.3.1 中文文本智能分级系统	5
3.3.2 硬件设备:	5
3.3.3 预训练语言模型 BERT 训练 SQuAD 问答任务:	5
3.3.4 语音识别技术功能:	6
3.3.5 模型选择与适应	6
第 4 章 系统实现	7
4.1 软件设计:	7
4.1.1 前端界面设计:	7
4.1.2 后端测试任务设计:	11
4.2 硬件设计:	14
4.2.1 硬件设备及基础配置	14
4.2.2 硬件模块划分	15
4.3 改进方法及过程:	16
4.4 系统部署方法	16
4.4.1 硬件设备及基础配置:	16
4.4.2 文本难度分级技术实现:	16
4.4.3 智能问答系统的搭建:	16
4.4.4 语音指令的接收与识别:	17
第 5 章 测试分析	17

5.1 概述	17
5.1.1 测试背景	17
5.1.2 条件与限制	17
5.1.3 测试资源	17
5.2 测试准备	18
5.2.1 测试环境	18
5.3 测试方案:	18
5.3.1 测试项目名称:数据测试	18
5.4 问答测试:	19
5.4.1 单元测试:	19
5.5 结论与评价:	21
5.5.1 进度	21
5.5.2 评价	21
At a + 11 - 12 11 14	
第 6 章 作品总结	
6.1 作品特色与创新点	
6.1.1 创意和技术路线评价:	
6.1.2 创意和技术路线总结	
6.1.3 工作量	24
6.1.4 数据和测试效果:	24
6.1.5 自我评价和总结	25
6.2 应用推广	25
6.2.1 应用拓展:	25
6.2.2 应用推广进一步提升	26
6.2.3 应用推广总结	26
6.3 作品展望	27
6.3.1 智能学习生态	27
6.3.2 智能化个性服务	27
6.3.3 探索多领域发展	27
6.4 总结	28
毎 7 辛 4 老 ナ 北	22
第 7 章 参考文献	29

第1章 作品概述

1.1主题创意来源与产生背景

本作品的主题来源于北京语言大学国际传播的定位与责任。我们希望通过 学科交叉,促进中华经典在国际学生中的传播与理解。我们首先关注到当今时 代资源与信息的隐私问题,以及大模型中的数据污染问题,提出了以本地化为 特色、语音交互实现智能问答的智能音箱。接着,我们立足北京语言大学,与 国际教育老师深入探讨了当前中华经典文章在国际传播中的现状,在这个基础 上,我们创造性地提出了实现中文分级、智能推荐、语音问答一体的面向国际 传播的中华经典著作智能阅读助手。

1.2作品的用户群体

本作品主要应用与国际中文教育,用户主要是留学生以及对中华经典有学习热情的外国人。

1.3主要功能

1.3.1 中文分级

根据《等级标准》中语言能力要求,对中华经典作品进行分级。

1.3.2 智能推荐

用户可以在 Web 平台中进行水平测试,系统根据测试结果推荐适合用户水平的阅读书籍,有利于用户的阅读提升。

1.3.3 语音问答

用户在阅读时,可以随时对故事理解提出问题,并通过智能音箱进行语音问答交互。

1.3.4 特色

- 保护书籍作者版权,本地化书籍数据,确保数据安全和合法性。
- •实现分级与智能推荐,帮助用户选择适合的阅读材料,提升阅读效果。
- 边缘机器学习设备提供相对准确性高的回答,避免了污染数据可能带来的误导。

1.3.5 推广前景

本作品不仅能够满足留学生和外国人学习中华经典的需求,还具有广阔的推广前景:

内容方面,在国际教育机构推广,作为中文学习的辅助工具。在中国文化 传播机构推广,促进国际人士对中国文化的深入了解。也可以与图书馆、教育 机构合作,提供智能阅读服务。

技术方面,这是团队在边缘计算的机器学习模式的探索,该技术基于有限的计算资源,jetson nano 实现端侧小规模 ai 的训练与实验,有强大的隐私保护和版权方面的应用前景

第2章 问题分析

2.1问题来源

在目前的国际中文教育领域,存在着几个明显的问题:

首先,学习者与学习资源之间存在巨大的不平衡。中国语言学习的热潮导致了学习者数量的迅速增加,但教育机构和资源供应未能同步跟上,导致高质量教育资源的匮乏,影响了学习者的学习体验和语言发展。并且,传统的讲授式教学模式仍然占主导地位,但缺乏足够的互动和实践环节,导致学生难以在实际应用中灵活运用所学,影响了语言交流能力的提升。

虽然目前已有一些在线中文教育平台,但其缺乏针对学者个性化的教学服务,也侧重与知识技能的教育,而少于汉语文化内涵的传播。

2.2现有解决方案

现有的解决方案包括传统的讲授式教学模式、中文学习应用以及智能对话 大模型。然而,这些解决方案都存在一定的局限性。首先,传统的讲授式教学 模式虽然是主流,但缺乏足够的互动和实践环节,并且便捷性低,难以完成大 规模的普及和覆盖。现有的中文学习应用注重技能培养,但对语言背后的文化 内涵和经典讲义的关注不足。目前,以 chatgpt 为例的语言大模型非常火热,它 在留学生学习汉语方面也能提供潜在的帮助,但值得注意的是,在交互中大语 言模型对于一些不确定的问题生成的回复,可能出现事实性错误,甚至夹带胡 言乱语,可能误导学生,影响学习效果。

2.3本作品要解决的痛点问题

与上述解决方案相比,本作品的智能音箱提供了更加本地化、语音交互的智能问答服务,旨在弥补高质量教育资源的匮乏,提升学习者的学习体验和语言发展。此外,本作品还引入了中文分级、智能推荐和语音问答等功能,打破传统教学模式的局限,促进学生更灵活地运用所学知识。相较于智能对话大模型,本作品基于 bert,以一些经典著作或教材进行下游任务训练,提供相对准确性高的回答,避免了可能带来的误导,保障学生获得准确可信的信息。

2.4解决问题的思路

为满足场景化汉语学习的需求并确保版权保护,我们计划采用端侧 AI 学习方法进行阅读理解式对话。该方法将使用户在语音交互系统中通过阅读文章的同时更深入地理解文章内容,进而提升其发音能力和发音水平。

我们将设计网页文本,并利用北语已有的文本分级技术来实现文本的个性化分配。通过个人测试数据的得分,我们将建立文章与用户的匹配关系。我们选取了汉语经典阅读文本《理解当代中国》以及一些中医药知识作为样例进行学习。这将有助于在 Jetson Nano 平台上微调 BERT 模型,确保其能够准确地执行问答功能。

此外,我们还将调用科大讯飞的语音转文字和文字转语音模块,以实现高效的人机交互体验。最终目标是开发一个场景化的私人学习助手应用,为用户提供更为个性化和高效的学习体验。

第3章 技术方案

3.1总体技术思路

本作品针对国际中文教育领域出现的问题矛盾提出以下技术方案:

- 1)基于中文文本智能分级技术实现网页端用户中文水平测评和中文经典作品分级,并依据等级匹配进行相应等级的中文经典阅读章节推荐。
- 2)语音交互系统:借助人工智能开发板和远场麦克风阵列模块两部分硬件设备搭载基于预训练语言模型 BERT 的 SOuAD 问答任务。
- 3)基于语音识别技术的唤醒词唤醒与信息采集,文本处理,答案生成音频 发声。

3.2技术路线框架图

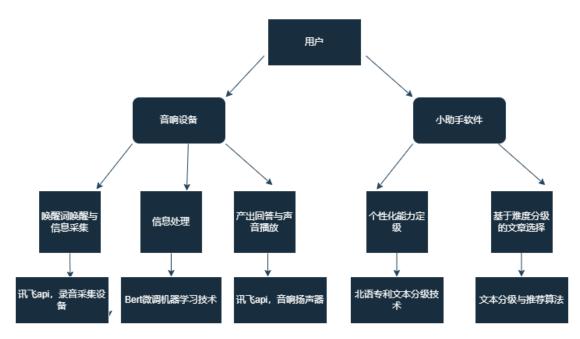


图 1 技术路线框架图

3.3详细技术介绍

3.3.1 中文文本智能分级系统

中文文本智能分级系统^[1]面向国际中文教育,以《等级标准》中语言能力要求为依据对中文文本进行难度自动评估,并提供相关文本语言信息的系统,是由北京语言大学国际中文学院殷晓君老师(学会会员)和根特大学 LT3 实验室 Dr.HUA Zheng(花正)共同研发的中文文本自动分级系统。

本作品在该分级系统的基础上通过 Flask 框架搭建网页端测评系统,从数据集中选取文本分级后形成测试试卷,同时形成评价体系,依据用户测试水平结果匹配相应分级文本推荐。

3.3.2 硬件设备:

Jetson Nano B01 是一款由英伟达(NVIDIA)推出的一款人工智能开发板, 旨在为开发者、研究人员和爱好者提供一个低成本、低功耗的平台,用于开发 和部署深度学习、机器学习和人工智能应用。

远场麦克风阵列连接科大讯飞 6 语音识别模块实现声源定位 ROS 功能。麦克风阵列是由一定数目的声学传感器(一般为麦克风)组成,对声场的空间特性进行采样并处理的系统。其主要作用有声源定位,抑制背景噪声、干扰、混响、回声,信号提取与分离。

3.3.3 预训练语言模型 BERT 训练 SQuAD 问答任务:

SQuAD (Stanford Question Answering Dataset)是一个用于机器阅读理解的任务和数据集。该任务的目标是让计算机阅读一个段落,通常是文章、新闻或故事的一部分,然后回答关于这个段落的问题。在我们的系统中,我们选择了中华经典故事作为文本,以实现阅读理解任务。计算机会读取这些故事的段落,并根据用户提出的问题提供答案。这样的系统可以帮助用户更好地理解和交互中华经典故事中的内容,从而实现智能问答的功能。数据集,以刘利老师主编的《高级中文读写教程("理解当代中国"国际中文系列教材)》为核心,提取其中的经典阅读文本,并补充收集了其他中国经典阅读故事。整理主题为:寓言故事、神话传说、历史文化、中国故事、成语典故等。对数据集进行清洗和格式化处理,按照 SQuAD 任务划分为训练集和测试集(8:2)。

3.3.4 语音识别技术功能:

唤醒词唤醒与信息采集,通过设置专有唤醒词,让在休眠状态下的设备进入等待指令状态,随后在用户提出相应命令或问题时将用户的问题转化成文本,该技术基于讯飞公司的信息语音收集处理方案,经过验证与使用证明已经有强大的可用性和识别效率。

文本处理,通过语音识别将用户命令或问题转变成文本格式,之后利用微调好的 BERT 模型进行文本处理,以获得该问题对应答案文。

答案生成音频发声,该技术基于新一代语音技术引擎,资源占用低,响应快,在语种方言种类方面识别精准度有提升,该技术在智能硬件使用时,能够帮助用户与机器人之间的语音信息交互效率增加。

3.3.5 模型选择与适应

预训练模型 BERT^[2] (Bidirectional Encoder Representations from Transformers) 是自然语言处理领域的一个重要里程碑。它在本作品中适用的优势包括以下几个方面:

- 1) 双向注意力机制: BERT 通过 Transformer 架构实现了双向(bidirectional)注意力机制,这意味着它在处理文本时可以同时考虑上下文两侧的信息,从而更好地理解句子或文本的含义。BERT模型更适于本作品中国际中文教育领域的中文经典阅读文本内容的处理,在处理精度和文本信息理解上 BERT 模型也有着丰富的机制保障。
- 2)丰富的模型参数进行预训练和微调: BERT 拥有大量的参数,通过大规模文本语料库上的预训练(pre-training)获得丰富的语言表示,然后通过微调(fine-tuning)适应特定任务。这种预训练-微调流程提高了模型在各种自然语言处理任务上的泛化能力。该泛化能力也让 BERT 模型在经过我们的参数微调之后更切合本作品中文经典阅读文本文本的处理和理解。
- 3) 多任务学习: BERT 在预训练阶段通过多任务学习(如掩码语言模型和下一句预测)获得了更好的语言表示能力。这种训练方式让 BERT 在不同任务之间具有更好的泛化能力,可以应用于多种自然语言处理任务,包括文本分类、问答系统、翻译、文本摘要等。同时 BERT 在预训练中进行了下一句预测任务,让模型更好地理解句子之间的关联,这在答案与问题有紧密联系的问答任务中能够有很好的应用效果

此外,在该算法的应用中我们用本项目数据集进行了训练和参数微调,让 BERT模型能够更好地适用于本问答系统的建立,提升了问题回答精确度。

第4章 系统实现

4.1软件设计:

4.1.1 前端界面设计:

1. 基于 Bert 模型的文本难度分级技术

我们引入北京语言大学国际中文教育殷晓君老师和根特大学共同研发的中文文本自动分级系统作为分级标准,以《基于<等级标准>的中文文本智能分级系统》为基础,通过个性化数据集与基于轻量化 BERT 语言微调模型的文本分级技术对文本的难度评估,搭建一个智能推荐系统,实现用户水平推荐及智能推荐。我们将数据集中的故事通过分级系统进行评测,分类为"初等、中等、高等"三个难度级别,设计了汉语水平测试题库,打造了用户阅读能力检测的简单个性化评判标准,科学的对个人语言能力进行评估,有助于在推荐文章阅读时进行分门别类的良好匹配。在题库中实现随机抽题形成水平评测问卷。本平台做出用户汉语水平能力判断并存储,根据用户的汉语水平推荐合适的学习资料。并将测试数据通过云端传入语音问答系统,实现对话功能。

2. 前端网页界面:

使用 HTML、CSS 和 JavaScript 构建网站的用户界面,包括登录界面、注册界面、首页、测试页面、测试结果页面等。经过测试后返回用户的个性化数据。



3. 国际中文水平测试与推荐系统的阅读文本数据集来源:

训练数据来源于 26 套国际中文教材文本,共计 5000 余篇文本。使用了丰富的语言学特征,包括 38 个词汇和句子特征构成的传统复杂度特征,51 个句法依存构式复杂度特征和 152 个语义依存构式复杂度特征,总计 241 个语言复杂度特征。进行数据收集、清洗和预处理等过程,构建为 JSON 格式的数据集,用于存储用户的文章库以及匹配问题和答案的数据。将其分为高中低三等级的阅读文本用于随机出题。

"每个国家、民族的义化传统十左万别,不同的国家、民族具有不同的风俗习惯。",

"在当今日益频繁的国际交往中,我们每到一地,都应该特别留意这一点。",

"在印度尼西亚,具有良好教养的人在彼此相识之时,应马上把自己的名片递给对方。",

"如果不送名片,那将难免受到对方长时间的冷遇。",

"在日本,你每天得准备递送40张名片。",

"在法国,礼节要求你将自己的身份列在名片上。",

"在丹麦,一位被邀请到朋友家做客的人应带上鲜花或者一些有趣的 精美礼品。"、

"在德国,如果你应邀做客,那么鲜花也是送给女主人的最好礼物, 但不能送玫瑰花,他们认为玫瑰花只能送给情人。",

"而在瑞士,你可以送1束,也可以送20束红玫瑰给你的生意朋友, 只要花的数目不是"3"就行;如果花的数目是"3",则意味着你们是情人。

"在法国,人们总是在拜访或参加晚宴的前夕送鲜花给主人。".

"不过,在法国千万别送菊花——除非你是去参加朋友的葬礼。",

"在日本,有些参加晚宴的宾客可能会提前离席而去,而且离席时一 般都是静悄悄的,不做正式的告别。",

"因为在这种场合做正式告别,会被视为扰乱宴会气氛,打扰其他在 场的宾客。".

"阿拉伯国家的人初次见面,不能送礼,否则会被视为行贿,还忌讳 将酒作为礼物送人:人们见面时,还不能问及家人。".

"美洲国家的人忌讳黑色和紫色,因为它们暗示结束友谊;人们还忌 讳用手帕作为礼物送人, 因为它常常和眼泪连在一起, 因此被看成不祥之 物。"

],

Γ

"格里斯认为齐白石不仅是中国的伟大画家,也是世界的伟大画家, 齐白石把全身心都投入到自然中去了,没有人比齐白石对自然的了解和感情 更深。老人对我们说,齐白石是独一无二的,齐白石画虾,便对虾的结构和 神态作了最为细致深入的研究,那种简洁有力的神奇画法,全世界都找不 到。格里才老人是一个大自然的卓越歌手,我以前从旧书旧杂志上看到过不 少关于他的介绍。",

"他在 1950~1952 年期间创作的风景画《伏尔加河远眺》, 具有极完

美的写实技巧,充满了浓郁的诗意。这样个希施金和列维坦的传人,却如此 推尝齐白石的绘画,真有点儿让我大惑不解。",

"我问老人是否可以去中国教学,老人听了却把头摇得像个拨浪鼓。",

"他认真地说;'我为什么要去教中国的画家?中国有自己的艺术和文化传统,我希望中国能够珍惜和保护自己的艺术和文化传统。'他还说有一种理论认为各民族的文化应互相融合,而他则认为各民族应该保持自己文化的独立、艺术的独立。老人甚至对我们大老远地跑来俄罗斯学习作画感到不以为然。",

"他认为中国人对自然界的一草一木、花鸟虫鱼都有极为独特的感受,中国画的结构也很棒,形式感很强。老人说他不是要固执地保护俄罗斯的文化,而是不希望看到全世界的艺术趋向同一。老人指着墙上挂着的齐白石的作品说,从这些作品中可以进入中国的文化和思想。我不得不承认老人的话很有道理。那是一种艺术上和文化上的'远眺'。我终于明白了齐白石为什么能够成为一代大师,也明白了其他众多画虾能手的画中到底少了些什么。所谓中国绘画从传统形态向现代形态的转变云云,是困扰了中国美术家将近一个世纪的难题。本世纪以来,不少前辈艺术家引进西方写实绘画技法以'刷新'中国绘画,其付出的努力的确令人钦敬,但取得的成就却令人怀疑。",

"齐白石之所以成为中国乃至世界的艺术巨匠,与其认为他受到了西方强势文化的影响,努力实现所谓从传统向现代的转变,还不如说他坚持固守了中国艺术精神、并将其推向了极致更为恰当。",

"据我的理解,书画同源、诗书画印的融为一体,是中国画区别于西方绘画的根本所在,亦是中国画中的中国艺术精神之根本体现。",

"从齐白石的毕生艺术追求及其所取得的伟大成就来看,艺术创作中的求新求变,并不意味着一定要吸收和融入异域文化的成分,'借复旧以趋新'有时也不失为一条创造的途径。",

"唐代的古文运动以及晚清的碑学复兴,意大利文艺复兴时期古希腊雕刻的出土,都曾极大地推动了当时文学或艺术的创新。从书画同源的观点和角度来考察齐白石的艺术,能够比较准确地把握其艺术创作的根本特点。齐白石甚至在进行艺术鉴赏时,亦用了"书"来作为评"画"的标准,如他曾说李可染的画是画中草书,徐青藤的画也是草书,而他自己的画则是正

楷。",

"或有对齐白石'诗第一,印第二,字第三,画第四'的自我评价不以为然者,但也有论者认为这样的评价不无道理,认为齐白石整体艺术创作中的最大成就即在于诗歌艺术上的。",

"不论各家观点如何纷争,诗书画印都是齐白石艺术创作成就中不可分割的部分,它们相互影响,相互交融,早已成为一个整体,这是已为学界所公认了的。"、

"这样的整体当然完美地体现出了中国艺术的精神。",

"从这里当然也就'可以进入中国的文化和思想'。",

"诚哉格里才斯言。"

]

]

4.1.2 后端测试任务设计:

1. 网站后端

使用 Flask 构建系统的后端逻辑,处理用户的登录、注册、测试请求,并与用户数据库进行交互。

2. 硬件语音交互后端

主要负责数据处理、语音识别、文本分级和智能对话等功能。其中,数据处理模块负责接收用户的语音输入并转换成文本,然后利用 BERT 模型进行文本处理和匹配。智能对话模块根据用户的提问从数据库中获取相应的答案,并将答案转换成语音输出。

3. 智能问答系统的搭建

1) Bert 中文预训练模型

hfl/chinese-roberta-wwm-ext-large 模型是基于 BERT 的中文预训练模型,由哈工大讯飞联合实验室(HFL)开发,是 RoBERTa(A Robustly Optimized BERT Pretraining Approach)的扩展版本。它在 RoBERTa 模型的基础上进行了改进,适用于中文语境。我们在这个预训练模型上进行微调。将训练集作为模型输入,在基于 pytorch 的 Transformer 框架下进行微调,并根据评估结果对模型进行优

化调整。

训练集上的准确率和召回率为: 0.84 和 0.84 验证集上的准确率和召回率为: 0.83 和 0.8 其表现如下:

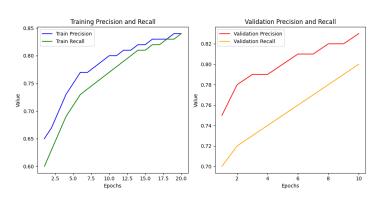


图 2 模型评估数据

但大部分时候我们更期望提出这篇文章能回答的问题,在一定程度上问题 比答案更重要。比如,协助教师出题,协助证券分析师快速找到研报、新闻简 讯中的核心事件。因此,我们讨论如何基于 SQuAD 任务,训练问题生成模 型。

4. 基于 BERT 预训练模型的问答任务数据集来源:

《理解当代中国》国际中文读写教程,围绕当代中国社会、政治、经济、文化、教育、科技、生态等主题建构话题,旨在帮助学生全面了解中国国情和制度政策,直观感知当代中国的发展变化,读懂中国发展背后的深层逻辑,同时结合自身的文化背景与经历、见闻,从国际视角理解中国议题,站在人类命运共同体的立场去分析和探讨相关问题;在内容学习过程中,进一步夯实中文基本功,提升中文听说读写能力,提高对时政话题类真实语料的理解能力,以及用中文进行有深度的沟通与表达的能力,促进思辨能力、跨文化沟通能力等进一步提高。

进行数据收集、清洗和预处理等过程,构建为 JSON 格式的数据集,用于存储用户信息、测试数据、测试结果等关键数据,以及存储用户的个性化数据、文章库以及匹配问题和答案的数据。

例如《理解当代中国》国际中文读写教程第一单元课文二:

```
"title": "袁隆平的中国梦",
"paragraphs": [
```

"context": "杂交水稻之父"袁隆平说,他曾经做过这样一个梦: 田里的 水稻有高粱那么高,穗子有扫帚那么长,谷粒有花生米那么大,他 就 坐在这样的稻穗下乘凉。这就是袁隆平的"禾下乘凉梦", 也是 他的中国梦的 重要组成部分。袁降平的中国梦有三个目标:一是让水稻产量实现数倍增 长, 让中国 14 亿人民吃饱饭; 二是让中国水稻栽培技术传到世界各国, 惠 及全世界人民;三是让每年增产的稻谷再多养活8000万人。透过这个梦,我 们看到了一位伟大科学家的赤子之心,也仿佛依稀看 到了袁隆平先生毕生为 解决世界粮食安全问题奋斗的身影。 袁隆平一生致力于杂交水稻技术的研 究、应用与推广,发明了"三系法"籼型杂交水稻,研究出"两系法"杂交水 稻, 创建了超级杂交稻技术体系, 提出并实施"种三产四"丰产工程, 成功推 广 超级杂交稻应用技术,使水稻的单产和总产量得以大幅度提高。他研发的 高产杂交水稻品种使得水稻全年平均亩产从300公斤逐步提高到500公斤、 700 公斤、800 公斤、1000 公斤、1500 公斤,并于 2000 年、2004 年、2011 年、2014年实现了大面积示范每公顷10.5吨、12吨、13.5吨、15吨的目标, 使得中国用全球 7%的耕地养活了世 界近 20%的人口。 袁隆平研发的杂交水 稻不仅养活了14亿中国人,还帮助许多发展中国家解决了粮食问题。他曾经 带领团队到越南、印度、菲律 宾和非洲的多个国家, 无偿传授杂交水稻种楦 技术。因为他的到来, 无数发展中国家的贫困人民吃上了饭, 也吃饱了饭。 由于袁隆平在 为人类提供营养丰富、数量充足的粮食方面作出了突出贡献, 他于 2004 年被授予了国际上农业粮食领域的最高奖项——世界粮食奖。 袁隆 平不只是中国的袁隆平, 也是世界的袁隆平。袁隆平的中 国梦联通了世界人 民的梦想, 他所取得的科研成果不仅解决了中国粮食自给难题, 也为世界粮 食安全作出了重大贡献",

```
"questions": [
{
    "id": "3",
```

"question": "为什么说"袁隆平不只是中国的袁隆平, 也是世

界的袁隆平"? ",

```
"answers": [
```

"text": "袁隆平的中 国梦联通了世界人民的梦想,他所取得的科研成果不仅解决了中国粮食自给难题,也为世界粮食安全作出了重大贡献。",

5. 反馈与迭代系统

用户在使用过程中的反馈会被系统收集和分析,包括但不限于语音识别的准确性、文章推荐的相关性以及语音输出的自然度。这些反馈信息将被用于调整和优化算法,实现系统的自我学习和迭代更新。同时有基于边缘设备的机器学习技术,允许系统在不依赖云端服务器的情况下进行学习和更新。这不仅大大降低了系统的延迟,还提高了数据处理的安全性和隐私性。通过这样的反馈与迭代系统,我们能够确保智能对话音响系统不断进步,更好地满足用户的需求,提供更加个性化和高效的服务。

4.2硬件设计:

4.2.1 硬件设备及基础配置

Jetson Nano B01 系统配置,团队为开发板配置显示屏、键盘、鼠标等外设,并通过 SD 卡为系统烧录 linux 环境。配置 ssh 远程连接。在终端输入 IP 地址查询相关指令来获取本机 IP 地址,通过 SSH 服务远登录并管理开发板操作系统并搭建对应。语音指令的接收与识别,选择远场麦克风阵列,科大讯飞 6 语音识别模块实现声源定位 ROS 功能。麦克风阵列实现 360°声源定位、语义解析,结合扬声器进行语音播报。接入科大讯飞离线语音识别引擎,设置被动唤醒(系统监听唤醒词进入待机状态),一旦识别到唤醒词,立即进入主动聆听(系统实时主动聆听用户语音指令)。实现音字转化功能,接入科大讯飞语音识别云平台 TTS/SST,实现文字语音互转。



图 3 开发板

4.2.2 硬件模块划分

在硬件系统上,系统有助手唤醒与采集,文本处理、音频发声模块三个区域组成。

采集与唤醒,通过设置专有唤醒词,帮助机器进入,随后将用户的问题转 化成文本,技术基于讯飞公司的信息语音收集处理方案,该技术经过验证与使 用证明已经有强大的可用性和识别效率。

数据处理,结合 Jetson Nano 开发模块的 GPU 算力,团队选择了 BERT 作为 开发模型进行微调,结合算法调整的精确度和处理效率,将问题与文本库的文本进行匹配,出色的实现了算法的高性能利用(10%),使得问题高效率匹配到对应的答案并进行转出。

发声模块,结合讯飞技术解决方案,通过自组装发声模块根据难度设置与 转化将答案进行清楚流利的表达,合理化实现对话流程的功能。

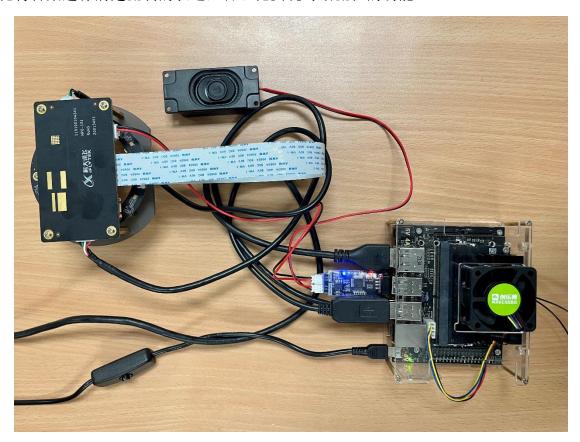


图 4 系统实物图

4.3改进方法及过程:

本项目的实施过程中,我们遵循了数据收集、处理和反馈迭代的系统方案,确保了系统的高效性和准确性。特别是通过采用 NVIDIA Jetson Nano 开发板的 GPU 算力和基于 BERT 模型的微调,实现了高效精确的文本处理和智能问答功能。我们还引入了基于边缘设备的机器学习技术,进一步降低了系统的延迟,提高了数据处理的安全性和隐私性。尽管系统在实现个性化阅读辅助和智能问答方面取得了一定的成效,但我们也意识到了存在的不足和改进空间。例如,系统的用户界面(UI)和用户体验(UX)方面仍有待优化,以提供更加直观和友好的交互方式。此外,文本难度分级技术虽然能够实现基本的个性化推荐,但其精准度和适应性仍需进一步提升,以更好地满足不同用户的需求。在未来的工作中,我们计划继续优化系统的性能,扩大教育内容的覆盖范围,并探索更多的应用场景。同时,我们将重视用户反馈,不断迭代更新系统,提高智能对话音响系统的准确性、响应速度和用户满意度。我们相信,通过不断的努力和创新,我们能够为汉语学习者提供更加丰富、便捷和智能的学习辅助工具,促进中华文化的国际传播。

4.4系统部署方法

4.4.1 硬件设备及基础配置:

使用 Jetson Nano B01 作为硬件平台,配置显示屏、键盘、鼠标等外设,并通过 SD卡为系统烧录 linux 环境。建立工程文件。

运行环境: Ubuntu 18.04 (arm64)、windows 10 (x86)

4.4.2 文本难度分级技术实现:

搭建智能推荐系统,利用分级系统对文本进行评测并实现用户水平测试及 智能推荐。

4.4.3 智能问答系统的搭建:

基于 BERT 预训练模型的 SOuAD 问答任务,通过微调实现智能问答功能。

4.4.4 语音指令的接收与识别:

选择远场麦克风阵列实现声源定位,通过科大讯飞语音识别模块实现语音指令的接收与识别。

第5章 测试分析

5.1概述

5.1.1 测试背景

实际运行环境: Ubuntu 18.04 (arm64)、windows 10 (x86)

测试环境: Windows 10 (x86)

测试环境与实际运行环境之间存在的差异,单机测试与联网的实际运行环境存在的差异以及并发操作等情况难于处理,很难做到完全基于实际情况的测试

5.1.2 条件与限制

时间限制: 本次测试的时间范围: 2024/4/10-2024/4/12

技术限制:系统开发和测试均主要用 python 和 html 语言完成,网页与程序 使用 flask 框架连接。

安全和隐私限制: 遵守相关法规和标准

5.1.3 测试资源

硬件资源:已确保测试所需的语音交互系统,包括开发板、语音阵列以及其他硬件资源的可用性和充足性。

软件资源:已确保测试所需的开发工具、测试工具、集成环境和数据库等 软件的安装和配置。已验证所有相关软件版本和依赖项符合测试要求。

5.2测试准备

5.2.1 测试环境

(1) 搭建测试环境:已创建适用于单元测试和集成测试的测试环境。 配置所有必要的软硬件环境,包括数据库、服务器设置和网络连接等。 对测试环境进行验证和功能测试,确保其稳定性和可用性。

测试数据

- (1)准备测试数据: 获取适用于单元测试和集成测试的测试数据集。 确保测试数据覆盖各种情况和数据类型,以确保全面性和准确性。
- (2)数据清理和准备:对测试数据进行清理、格式化和准备,以确保数据的一致性和可用性。创建测试数据文档,包括数据格式、范围、数据关联等详细信息。

5.3测试方案:

5.3.1 测试项目名称:数据测试

通过对数据来源和数据规模的复查与分析进行数据可靠性和多样性真实性的测试。我们测试的数据来自《理解当代中国》书籍和搜集到的中医数据抽样一共有: 6281条。

经过对《理解当代中国》书籍和搜集到的中医数据抽样审查,结论其具有可靠性和多样性,审查生数据的具体样例如下:

"question": "关于反佐配伍,在吴茱萸汤中加入少许黄连反佐,能起到什么作用?",

"id": "medicine_question_5",

"is impossible": false,

"answers": [{"text": "用以防止方中吴茱萸、人参、干姜等品辛热太过,从而达到温降肝胃、泄浊通阳而止头痛的功效。",

"answer start": 129}]

"question": "时令是怎么根据五行的变化互分胜负的?",

"id": "medicine question 9",

"is impossible": false,

"answers": [

"text": "春胜长夏,长夏胜冬,冬胜夏,夏胜秋,秋胜春,这就是时令根据五行规律而互相胜负的情况。",
"answer_start":15}]

5.4问答测试:

5.4.1 单元测试:

表 1 单元测试结果

模块	测试内容 (函数)	测试功能	是否成	是
			功	否
				修
				正
模块1	网页实际使用打开与	建立 web 端,生成题目,用	√	
网页问	测试	户通过做题,通过 web 端进		
答		行能力水平测试,将水平匹		
		配文章到系统。		
模块2	唤醒: 你好小飞	输入数据,可以运行成功无	\checkmark	
Stt		报错		
	简单语音转文字: 你	输入数据,可以运行成功无	\checkmark	
	好	报错,成功实现文字		
	简单语音转文字:我	输入数据,可以运行成功无	\checkmark	
	的问题是	报错,成功实现文字		_
	简单语音转文字:谢	输入数据,可以运行成功无	\checkmark	_
	谢	报错成功实现文字		_
模块三	袁隆平是如何为中国	txt 文,并将分词结果写入到	\checkmark	_
数据分	的农业做出贡献的?	另一个文件中。正确回答对		_
析与匹		应书本的问题。		
配回答	袁隆平是中国的哪一	txt 文,并将分词结果写入到	\checkmark	
	代杂交水稻育种专	另一个文件中。正确回答对		
	家?	应书本的问题。		
	杂交水稻是如何改变	txt 文,并将分词结果写入到	\checkmark	_
	中国的农业生产的?	另一个文件中。正确回答对		_
		应书本的问题。		
	袁隆平被称为"杂交	txt 文,并将分词结果写入到	\checkmark	_
	水稻之父",这一称	另一个文件中。正确回答对		_
	号是如何得来的?	应书本的问题。		

5.5结论与评价:

5.5.1 进度

已完成测试,并对未成功或偏差较大的部分做了修正。

5.5.2 评价

我们基于公平透明可重复的准则完成了测试工作,其各项测试问题均来自于相关知识的检索,有部分问题会有一定关联性,可能不能完全反应效果,但整体符合良好的测试效果准则。

第6章 作品总结

6.1作品特色与创新点

"慧语精灵"是我们团队针对在华留学生和对汉语学习对中国经典感兴趣的 外国用户开发的通过语音采集,文本分级和边缘设备机器学习技术的一款经典 阅读的小助手,它的产生是团队为帮助外国用户学习中文以及了解中国文化打 造,结合北语技术积累以及技术创新,切合国家号召、满足这一市场需求的系

6.1.1 创意和技术路线评价:

1. 个性化阅读推荐技术

本系统利用北语语合中心开发的基于 Bert 模型的中文文本分级技术与个性 化数据库与文本分级技术打造了用户阅读能力检测的简单系统,根据这个系统 做出用户能力判断并存储。同时,用户通过将不同的设备导入机器中并进行分析得到文本集,基于用户能力随机匹配对应文章方便用户阅读,同时将文章导入进入音响之中。本项目核心产品"慧语精灵"通过智能化技术,为在华留学生和汉语学习者提供个性化的阅读体验,根据用户的阅读习惯和水平,推荐适合的经典文学作品,帮助用户提升中文水平和文化素养。这使得我们的产品具有强大的个性化与定制化特点,结合 AI 的技术,实现针对性辅助阅读和学习。

2. 边缘设备的机器学习技术与隐私安全保护

我们创造性的采用边缘设备的机器学习技术进行工作,通过本地化微调的 Bert 模型,用人工智能的技术在区域上进行模型的训练和评估。该技术的最重要特征就是离线,允许系统在不依赖云端服务器的情况下,实现对用户阅读行为和反馈的实时分析,为用户提供个性化的学习建议和推荐。它可以最好地保护文本版权隐私性与用户数据隐私,打造私人化学习助手。不仅实现了系统延迟优化,还保证了文本数据版权的安全性。

3. 语音识别与发声技术

在硬件系统上,影响有唤醒与采集,处理、发声三个模块组成。采集与唤醒,通过设置专有唤醒词,帮助机器进入,随后将用户的问题转化成文本,技术基于讯飞公司的 API,该技术已经有强大的可用性和识别效率。发声模块,结合讯飞已有技术,通过自组装发声模块将答案进行清楚流利的表达,合理化实现对话流程的实现。结合语音识别和发声技术,实现文字转语音功能,使用户可以通过听力方式进行阅读,提供更加直观和便捷的学习体验。

4. 分级科学

引入北京语言大学国际中文学院殷晓君老师(学会会员)和根特大学 LT3 实验室 Dr.HUA Zheng(花正)共同研发的中文文本自动分级系统,面向国际中文教育,以《等级标准》中语言能力要求为依据对中文文本基于语言学知识和

机器学习模型进行难度自动评估,并提供相关文本语言信息。帮助产品具有文本难度选择和用户能力评估的特有能力。通过对文本的难度评估,将文本难度分为低中高三个层次方便进行分发,有效保证语言预料符合教育部科学认证要求。同时,利用同样的分类技术与数据库,打造针对个人能力的技术分级,科学的对个人语言能力进行评估,有助于在文章阅读时进行分门别类的良好匹配。

5. 可拓展性

因为基于边缘设备进行计算与数据库的接入,本产品具有高度的可拓展性,用户可以使用不同的文本语料进行训练得到良好的效果,同时设备便携,真正可以实现随时随地的学,随时随地得到提升。

6. 反馈与迭代系统

用户在使用过程中的反馈会被系统收集和分析,包括但不限于语音识别的 准确性、文章推荐的相关性以及语音输出的自然度。这些反馈信息将被用于调整和优化算法,实现系统的自我学习和迭代更新。同时有基于边缘设备的机器 学习技术,允许系统在不依赖云端服务器的情况下进行学习和更新。这不仅大 大降低了系统的延迟,还提高了数据处理的安全性和隐私性。

通过这样的反馈与迭代系统,我们能够确保智能对话音响系统不断进步, 更好地满足用户的需求,提供更加个性化和高效的服务。

6.1.2 创意和技术路线总结

创意基于汉语经典阅读助手的概念,技术路线采用了个性化阅读推荐、语音识别与发声、边缘设备的机器学习和文本分类等先进技术,实现了智能化的阅读辅助功能,为在华留学生和汉语学习者提供了一种全新的学习方式。这是一款软硬件设备结合,结合整合现有语音识别与发声技术,立足北语文本分级技术以及基于边缘设备的奇迹学习设备创新打造的智能对话音响系统。将软件的信息采集与文章选取技术与硬件的声音采集、分析处理、发声三位一体结合形成的系统。本项目充分将创新的想法和前沿的技术相结合,保护文本版权与用户个人的私密性,打造私人化学习助手,提供了符合用户需求的个性化阅读解决方案,技术路线清晰,实现了产品的核心功能和竞争优势,具有较高的创新性和前瞻性。通过不断的技术研发和优化,我们取得了一定的成果,但仍需要进一步完善和提升技术水平,以应对日益增长的市场需求和竞争压力。

6.1.3 工作量

在项目开发过程中,项目的工作量较大,涉及到市场调研、产品设计、技术开发、测试和推广等多个方面。团队成员需要充分协作,分工明确,工作效率高,才能保证项目的顺利进行。在过程中,我们面临着各种挑战和困难,但通过团队的共同努力和不懈探索,最终取得了一定的进展。

6.1.4 数据和测试效果:

1. 数据集

·以北语老师主编的《高级中文读写教程("理解当代中国"国际中文系列教材)》为核心,提取其中的经典阅读文本,并补充收集了其他中国经典阅读故事。 ·整理主题为:寓言故事、神话传说、历史文化、中国故事、成语典故等。 ·对数据集进行清洗和格式化处理,按照 SQuAD 任务划分为训练集和测试集(8:2)。

在项目开发过程中,我们进行了大量的数据收集和分析,包括用户调研、市场调查、产品测试等。通过数据分析,我们不断改进产品设计和功能,提升用户体验。同时,我们进行了系统的测试和评估,确保产品的稳定性和性能表现。虽然在测试过程中发现了一些问题,但我们及时进行了修复和优化,最终取得了较好的测试效果。

2. 数据、测试效果、以及用户反馈评价与总结:

在项目开发过程中,我们进行了大量的数据收集和分析,包括数据文本收集、用户调研、市场调查、产品测试等。通过数据分析,我们不断改进产品设计和功能,提升用户体验。同时,我们进行了系统的测试和评估,确保产品的稳定性和性能表现。虽然在测试过程中发现了一些问题,但我们及时进行了修复和优化,最终取得了较好的测试效果。经过多轮测试和改进,产品的稳定性和性能得到了验证,通过市场调研和用户反馈收集到的大量的数据表明,用户反馈积极,体验良好,取得了初步的市场认可和口碑。

6.1.5 自我评价和总结

综上所述,我们对项目的自我评价是积极的。本项目团队致力于打造一个结合语音识别、机器学习和个性化推荐技术的汉语经典阅读助手,为在华留学生和汉语学习者提供更便捷、高效的学习体验。我们的创意具有创新性和前瞻性,技术路线清晰,工作量虽然较大但团队合作效率高,数据和测试效果也得到了肯定。然而,面临着市场竞争激烈、技术进步迅速等挑战,我们也意识到项目仍有改进空间,需要不断努力和完善、不断的技术创新和市场拓展,以更好地满足用户需求和市场竞争,提升产品品质和服务水平,拓展市场份额,实现项目的可持续发展。我们的核心项目"慧语精灵"-汉语经典阅读助手具有明显的创新特色和市场前景,通过持续的努力和不断的创新,相信将会取得更大的成功和成就。

6.2应用推广

6.2.1 应用拓展:

1. 国际化发展

在国际化教育合作和海外市场拓展方面,我们可以与海外教育机构、留学中介等合作,推广我们的产品和服务。通过本土化定制、多语言支持等方式,适应不同国家和地区的需求,拓展海外市场。

2. 产业链延伸

可以考虑向上游产业链延伸,与出版社、教育资源提供商等合作,获取更 多优质阅读资源,丰富产品内容。同时,可以向下游产业链延伸,与在线教育 平台、智能硬件厂商等合作,拓展产品应用场景和销售渠道。

3. 技术创新

不断跟踪和应用新技术,提升产品的技术水平和竞争力。例如,结合虚拟现实(VR)和增强现实(AR)技术,打造沉浸式阅读体验;利用区块链技术,保障内容版权和数据安全等。同时,我们还将投资于语音识别技术,使用户可以通过语音交互进行更自然、便捷的学习体验。

4. 个性化服务

进一步深耕用户需求,提供个性化定制服务,包括个性化推荐、学习路径规划、学习成绩跟踪等。通过大数据分析和人工智能技术,实现精准营销和个性化学习,提升用户黏性和忠诚度。

6.2.2 应用推广进一步提升

1. 多渠道推广

我们将采取多种渠道进行推广,包括线上和线下渠道。线上渠道可以利用 社交媒体、应用商店推广、内容营销等方式,增加产品曝光度和用户获取;线 下渠道可以通过与各大学校达成合作、校园宣传、教育机构和语言培训机构合 作等方式,扩大产品影响力和用户群体。将产品推广到校园和教育领域,为学 生和教育工作者提供专业的中文阅读助手。

2. 定向推广

针对不同的用户群体,我们将制定针对性的推广策略。针对在华留学生,可以通过留学生社区、校园活动等方式进行推广;针对汉语学习者或对汉语学习感兴趣的外国人,可以与汉语培训机构、语言学校等合作,提供定制化的推广方案,通过线上线下渠道的营销和推广,吸引更多自学者和汉语培训学员使用产品,扩大用户群体。

3. 内容优化

不断丰富和优化产品内容,增加经典阅读材料的种类和数量,提升用户粘性和满意度。同时,结合用户反馈和数据分析,不断改进产品功能和用户体验,提高产品的市场竞争力。

4. 品牌建设

加强品牌宣传和形象塑造,提升产品知名度和美誉度。通过与知名教育机构、媒体合作,扩大品牌影响力和市场份额。同时,通过参加行业展会、举办线下活动等方式,提升产品的行业地位和竞争力,提升品牌知名度和用户粘性。

6.2.3 应用推广总结

综上所述,我们将通过多渠道推广、内容优化、品牌建设等方式,提升产

品的市场知名度和竞争力。同时,通过国际化发展、产业链延伸、技术创新和个性化服务等途径,拓展产品的应用场景和市场份额,实现更广阔的发展前景。

6.3作品展望

6.3.1 智能学习生态

我们将在本作品的基础上构建一个智能辅助学习生态系统,与其他教育科技公司、学术机构、行业专家形成协同关系。通过整合各方资源,实现全方位的学习支持,在平台上实现包括在线学习、实施辅导、学科交流等板块。引入个性化教学设计、职业规划、课程辅助理解等方面,切实帮助学习者更加轻松地理解和获取包括语言技能、中华传统文化等知识。这一生态系统的建设旨在提供更为全面的学习解决方案,使用户能够在不同领域获得更丰富的知识和技能。

6.3.2 智能化个性服务

未来,我们将更加注重个性化服务的智能方向发展。通过深度学习和用户 行为分析,我们期望对用户需求实现更精准的洞察,为用户提供更贴近个性化 需求的学习辅助和阅读建议。使产品更好地满足用户的个性化学习需求,提升 用户满意度和忠诚度。

6.3.3 探索多领域发展

我们将在本作品基础上结合对应领域的数据,探索多领域的拓展,包括医疗、农业、艺术、新能源等领域。通过将本作品拓展应用于这些领域,期待为社会带来更广泛的影响和更深远的变革。

1. 医疗领域

通过一些针对性的医疗领域数据,训练微调深度学习模型,致力于将本作品拓展开发为创新的医疗辅助工具和服务。并结合大数据分析开发辅助医疗诊断问答系统,帮助医生提高诊断准确性和效率,帮助患者初步了解症状和病因。我们也将探索数字化健康监测和远程医疗服务,为用户提供更便捷、更智能的

健康管理方案。

2. 农业领域

通过整合先进的传感技术、大数据分析和深度学习模型训练,我们将推动 农业生产的智能化和精准化。我们将计划开发农业信息管理系统,帮助农民实 现对土壤、气象等数据的数字化实时监测,提高农业生产的效率和质量,帮助 农民扩大生产规模,打破当前未体系化的家庭式生产方式的规模局限性。此外, 我们还将探索农业科技与可持续农业的结合,以推动更环保、资源高效利用的 农业发展。

3. 艺术领域

在艺术领域,我们将探索数字技术与艺术形式的深度融合。通过虚拟现实 (VR)、增强现实 (AR)等技术,我们将创造出更为沉浸式和交互性强的艺术体验。我们结合艺术方向数据计划推出数字艺术平台,为艺术家提供展示和创作的空间,同时为观众提供全新的艺术欣赏方式以辅助其理解和欣赏作品。此外,我们还将积极支持与艺术教育机构的合作,促进数字艺术技术在教育领域的应用,培养更多艺术创意人才。

4. 新能源领域

在新能源领域,我们将借助先进的能源科技,推动清洁能源的发展。通过与可再生能源行业的合作,我们计划开发智能能源管理系统,帮助企业和家庭更高效地利用太阳能、风能等可再生能源,使得新能源与普通消费者的生活更进一步,提升社会对新能源的关注度。我们也将关注能源储存技术的创新,以提高清洁能源的可靠性和可用性。我们的目标是结合目前系统功能在新能源领域发挥技术创新的力量,推动可持续能源的广泛应用。

6.4总结

综上所述,汉之慧教育科技有限公司的核心产品"慧语精灵"-汉语经典阅读助手具有明显的创新特色和市场前景。在现有基础上,我们将继续优化产品功能和用户体验,增加更多的学习资源和个性化定制服务,满足不同用户的需求。加强国际教育合作,拓展海外市场,将产品推广到更多的国家和地区,实现国际化发展。加大对技术研发的投入,跟踪和应用最新的技术趋势,不断推出创新产品和服务。通过持续的努力和不断的创新,相信将会取得更大的成功和成

第7章 参考文献

- [1] 殷晓君.基于依存构式的文本复杂度分级特征体系构建及效度验证[J].语言教学与研究,2022(06).
- [2] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.